Проверка гипотез о зарплатах

Как устроен `notebooks/hypothesis_testing.ipynb`,
зачем нужен каждый шаг и как читать статистику,
если вы только начинаете

9 173
вакансии с указанной зарплатой

21
гипотеза: от таргета до дат

5-fold
единая кросс-валидация

14 / 6 / 1
подтверждена / частично / нет

Учебные материалы по проекту «Job Postings with Salaries» · 2026
Ноутбук: Python 3.13, pandas, scipy, scikit-learn, statsmodels, matplotlib, seaborn

Содержание

Методичка идёт от общего к частному: сначала — что это за ноутбук и на каких данных он работает, затем — минимальная теория, потом — разбор кода и всех 21 гипотез, и в конце — чек-листы, ошибки и словарь.

1. Что это за ноутбук и как он устроен 3

- 1.1. Задача и главный вопрос
- 1.2. Логика исследования: гипотеза → проверка → вывод
- 1.3. Три уровня чтения ноутбука

2. Данные 5

- 2.1. Что лежит в таблице
- 2.2. Целевая переменная и её особенности
- 2.3. Смещения и ограничения данных

3. Как запустить ноутбук 6

4. Минимум теории, без которого не прочитать выводы 8

- 4.1. Выборка, гипотезы и p-value
- 4.2. Какие тесты здесь используются и почему
- 4.3. Размер эффекта: значимо ≠ важно
- 4.4. Множественные проверки
- 4.5. Кросс-валидация и метрики
- 4.6. Утечка данных (leakage)
- 4.7. Наблюдательные данные и причинность
- 4.8. Пропуски и выбросы

5. Подготовка данных: что делает каждая ячейка 13

6. Вспомогательные функции: «двигатель» ноутбука 16

7. Разбор 21 гипотезы 20

- 7.1. Таргет: гипотезы 1–3
- 7.2. Роль и уровень: гипотезы 4–7
- 7.3. География и формат: гипотезы 8–11
- 7.4. Компания и платформа: гипотезы 12–14
- 7.5. Занятость и период: гипотезы 15–17
- 7.6. Текст и пропуски: гипотезы 18–19
- 7.7. Служебные признаки: гипотезы 20–21

8. Итоги: что действительно работает 31

9. Как применять это на практике 33

- 9.1. Алгоритм проверки своей гипотезы
- 9.2. Чек-лист перед публикацией вывода
- 9.3. Десять типичных ошибок
- 9.4. Вопросы и ответы

10. Словарь терминов 35

Приложение. Формулы и шпаргалка по коду 37

1. Что это за ноутбук и как он устроен

Это исследовательский ноутбук, а не производственный пайплайн. Его задача — не получить максимально точную модель, а аккуратно ответить на 21 вопрос о зарплатах и понять, какие признаки вообще стоит тащить в модель.

1.1. Задача и главный вопрос

Есть таблица вакансий с зарплатными вилками. Хочется понять, от чего зависит зарплата: от уровня позиции, страны, формата работы, компании, платформы, типа занятости, текста описания. И одновременно — какие из этих признаков реально полезны для прогноза, а какие создают лишь иллюзию знания.

Ноутбук отвечает на два разных вопроса, и их важно не путать:

Вопрос	Инструмент	Что считается ответом
Есть ли различие между группами?	Статистические тесты: Kruskal–Wallis, Mann–Whitney, χ^2, корреляции	p-value и размер эффекта
Помогает ли признак прогнозу?	Кросс-валидация: модель с признаком против модели без него	Прирост MAE в долларах

Именно поэтому почти каждая гипотеза проверяется дважды: сначала тестом «различаются ли группы», затем сравнением моделей «стало ли лучше». Первое отвечает на вопрос «есть ли сигнал», второе — «есть ли польза». Они не всегда совпадают: различие может быть статистически значимым, но настолько малым, что модель от него не выигрывает.

> **ПОЧЕМУ ТАК**
> Если проверять только модель, можно пропустить важный описательный факт: признак вроде бы не улучшает MAE, потому что дублирует другой. Если проверять только тесты, можно утащить в модель десяток значимых, но бесполезных признаков. Двойная проверка закрывает обе слепые зоны.

1.2. Логика исследования: гипотеза → проверка → вывод

Каждая из 21 гипотез оформлена по одной схеме. Понимание этой схемы важнее, чем знание конкретных чисел.

Шаг	Что происходит в ноутбуке	Пример (гипотеза 9)
1. Вопрос	Формулируется проверяемое утверждение, а не «интересно, как оно».	«Remote платят больше, чем onsite».
2. Данные	Берётся подвыборка, где признак заполнен; задаётся минимальный размер группы.	Вакансии с известным `workplace_type`, группы от 20 наблюдений.
3. Проверка	Тест на различия + модель с признаком и без + контроль на конфаундеры.	Kruskal–Wallis, затем Mann–Whitney по парам, затем OLS с контролем на ATS, роль, занятость, период.
4. Эффект	Считается не только p, но и величина: ε^2, разница медиан, проценты, прирост MAE.	Медианы 130k / 117,6k / 77k; премия remote +45 % → +5,9 % после контроля.
5. Вывод	Формулируется с оговоркой: подтверждена, частично, не подтверждена.	«Частично подтверждена».

В конце ноутбук собирает все выводы в таблицу `SUMMARY` и печатает распределение вердиктов. Это не формальность: сводка помогает увидеть, что большая часть гипотез подтвердилась, но практическая ценность у них разная.

Карта ноутбука

Блок	Что внутри	Зачем
0. Подготовка	Загрузка, нормализация периода и валюты, таргет, флаги, эвристики	Сделать данные сопоставимыми и создать признаки
Вспомогательные функции	Тесты, метрики, кросс-валидация, target encoding, журнал выводов	Зафиксировать единую методику для всех гипотез
1. Таргет	Гипотезы 1–3: логарифм, середина вилки, ширина	Выбрать, что именно предсказывать
2. Роль и уровень	Гипотезы 4–7: seniority, title, семейство, department	Понять, что известно о самой позиции
3. География и формат	Гипотезы 8–11: страна, remote, штат, пропуск страны	Отделить рынок от состава выборки
4. Компания и платформа	Гипотезы 12–14: ATS, компания, источник зарплаты	Найти прокси типа компании и проверить артефакты
5. Занятость и период	Гипотезы 15–17: тип занятости, исходный период, ошибки	Учесть формат оплаты и качество данных
6. Текст и пропуски	Гипотезы 18–19: description, индикаторы пропусков	Проверить самый сильный и самый обманчивый сигнал
7. Служебные признаки	Гипотезы 20–21: min → max, даты	Отделить утечку от полезного признака
8–9. Итоги	Сводная таблица, рекомендации, ограничения	Собрать результат и следующие шаги

1.3. Три уровня чтения ноутбука

Уровень «что происходит». Читайте только markdown-ячейки с выводами. Их 21 плюс введение и итог. Этого достаточно, чтобы понять результаты.

Уровень «как посчитано». Смотрите код после каждого вывода: какие данные отфильтрованы, какой тест вызван, какие метрики сравниваются. Обращайте внимание на `min_n`, `dropna` и на то, на какой подвыборке считается метрика.

Уровень «почему так». Сравнивайте альтернативы: почему логарифм, а не исходная шкала; почему Kruskal–Wallis, а не t-тест; почему target encoding, а не one-hot; почему прирост MAE, а не R^2. Этому посвящены разделы 4–6 и врезки «Почему так» в разделе 7.

> **ОСТОРОЖНО**
> Ноутбук нельзя читать как книгу «сверху вниз, пропуская код»: почти все вычисления опираются на объекты, созданные выше. Например, `BASE_PRED` считается один раз после подготовки данных, а потом используется в половине гипотез как точка отсчёта. Если запустить ячейку 13 в свежем ядре, будет ошибка.

> **КАК ЧИТАТЬ МЕТОДИЧКУ**
> Везде, где это полезно, текст разбит на четыре типа врезок. **Теория** — что это за понятие. **Почему так** — почему автор ноутбука выбрал именно этот приём. **Осторожно** — где легко ошибиться. **Результат** — что получилось на этих данных. Если вы спешите, читайте разделы 7–9 и врезки «Осторожно».

2. Данные

Все выводы ноутбука верны ровно настолько, насколько хороши данные. Поэтому начинать надо не с тестов, а с понимания таблицы и её ограничений.

2.1. Что лежит в таблице

Файл `data/raw/job_postings_with_salaries.csv` — около 60 МБ; в анализе — 9 173 вакансии (строки без границ вилки удаляются). Одна строка — одна вакансия. Основные поля:

Поле	Тип	Смысл и типичные значения
`title`	текст	Название вакансии: «Senior Data Engineer», «Registered Nurse».
`description`	текст	Полное описание вакансии; часто содержит обязанности, стек и иногда саму зарплату.
`salary_min`, `salary_max`	число	Границы вилки в исходной валюте и исходном периоде.
`salary_period`	категория	`year`, `month`, `week`, `day`, `hour`.
`salary_currency`	категория	USD, EUR, GBP, CAD, PLN и другие.
`salary_source`	категория	`ats` — сумма взята из структурированного поля платформы; `description` — вытащена из текста.
`ats`	категория	Платформа, через которую опубликована вакансия: greenhouse, workday, ashby, recruitee и др.
`company`, `company_id`	категория	Название и внутренний идентификатор компании.
`country_code`, `location`, `region`, `city`	категория	География; заполнены не полностью.
`seniority`	категория	`internship`, `entry`, `mid`, `senior`, `executive`; заполнено около 7 %.
`employment_type`	категория	full-time, part-time, contract, temporary.
`workplace_type`	категория	remote, hybrid, onsite.
`department`	категория	Подразделение: Engineering, Sales, Retail…; заполнено около 59 %.
`posted_at`, `first_seen_at`	дата	Дата публикации и дата, когда вакансию впервые увидел сборщик.

> ТЕОРИЯ
>
> **Категориальный признак** — это признак, значения которого являются метками, а не числами: страна, платформа, тип занятости. Его нельзя просто подставить в формулу как число: код «US = 1, FR = 2» создаст ложный порядок. Поэтому категории либо кодируют one-hot, либо кодируют порядковым номером и говорят модели, что это категория (так делает HistGradientBoosting), либо заменяют средним таргетом (target encoding).

2.2. Целевая переменная и её особенности

Целевая переменная — **середина вилки** `salary_mid = (salary_min_usd + salary_max_usd) / 2`, приведённая к долларам в год. Слово «приведённая» здесь ключевое: исходные суммы могут быть

почасовыми, недельными или в евро, и сравнивать их напрямую нельзя.

Распределение зарплат сильно скошено вправо: большинство вакансий — 50–150 тысяч, но есть хвост до сотен тысяч. Среднее в таком распределении уезжает за «типичным» значением, поэтому в описательной статистике используется медиана, а в модели — логарифм.

> **ПОЧЕМУ ТАК**
> Логарифм превращает мультипликативные различия в аддитивные: «зарплата выросла на 10 %» становится «прибавилось 0,095 в лог-шкале» независимо от уровня зарплаты. Для модели это удобнее: ошибка в 10 тысяч на зарплате 50k и на зарплате 200k — совершенно разные вещи, а в лог-шкале они сопоставимы.

2.3. Смещения и ограничения данных

- **Только вакансии с указанной зарплатой.** Компании, которые не раскрывают вилку, в данных отсутствуют. Это не случайная выборка рынка: скорее всего, в ней перепредставлены технологичные компании и платформы, где раскрытие обязательно или принято.
- **Одна неделя наблюдения** (5–12 октября 2026). Сезонность, тренды и «рынок до/после» проверить нельзя — это прямо признано в гипотезе 21.
- **Фиксированные курсы валют.** Все суммы пересчитаны по одному снимку курсов; валютные колебания не учитываются.
- **Стандартные допущения пересчёта:** 2 080 часов в год, 260 рабочих дней, 52 недели, 12 месяцев. Для частичных ставок это может искажать годовую сумму.
- **Пропуски не случайны:** `seniority` заполнен у 7 %, `department` — у 59 %. Пропуск связан с платформой и форматом работы, то есть является сигналом (гипотеза 11 и 19).
- **Эвристики.** Семейство профессии и штат извлечены регулярными выражениями, а не размечены вручную. Это воспроизводимо, но содержит ошибки.

> **ОСТОРОЖНО**
> Из этих данных нельзя сделать вывод «remote повышает зарплату на 6 %». Можно лишь сказать: «среди вакансий с указанной зарплатой remote-вакансии в среднем на 6 % дороже при прочих наблюдаемых характеристиках». Причина может быть в том, что remote-позиции чаще открывают компании определённого типа — и это не наблюдаемая характеристика.

3. Как запустить ноутбук

Ноутбук рассчитан на локальный запуск из корня проекта. Ниже — минимальный путь, который работает на Windows, macOS и Linux.

Шаг 1. Виртуальное окружение

```
python -m venv venv
# Windows
venv\Scripts\activate
# macOS / Linux
source venv/bin/activate

pip install pandas numpy scipy scikit-learn statsmodels matplotlib seaborn jupyter
```

Шаг 2. Данные

Файл должен лежать по пути `data/raw/job_postings_with_salaries.csv`. Путь не задаётся вручную: функция `load_data()` в `src/utils.py` вычисляет корень проекта от расположения самого файла.

```
# src/utils.py
def load_data():
    root = Path(__file__).resolve().parent.parent
    path = root / "data" / "raw" / "job_postings_with_salaries.csv"
    return pd.read_csv(path)
```

Шаг 3. Запуск

```
jupyter notebook
# или
jupyter lab
```

Откройте `notebooks/hypothesis_testing.ipynb` и выполните **Kernel → Restart & Run All**. Именно «Run All», а не отдельные ячейки: ноутбук хранит состояние в объектах между ячейками.

Шаг 4. Сколько ждать

Основное время уходит на кросс-валидацию и текстовые модели (TF-IDF + Ridge). На ноутбуке среднего класса полный прогон занимает несколько минут; если запускать только разделы 1–7, будет быстрее. Графики строятся по ходу выполнения и вставляются в вывод ячеек.

> **ПОЧЕМУ ТАК**
>
> В начале ноутбука есть строка `PROJECT_ROOT = Path.cwd().parent if Path.cwd().name == "notebooks" else Path.cwd()`. Она нужна, чтобы импорт `from src.utils import load_data` работал и при запуске из папки `notebooks`, и из корня проекта. Это маленькая, но частая причина ошибки `ModuleNotFoundError`.

> **ОСТОРОЖНО**
>
> В ноутбуке отключены предупреждения: `warnings.filterwarnings("ignore")`. Это удобно для читаемости вывода, но опасно при отладке: вы можете не заметить предупреждение о делении на ноль, пропущенных значениях или устаревшем параметре. Если что-то считается странно, первым делом уберите эту строку.

Что должно появиться в выводе

- Строка о числе исходных и оставшихся наблюдений, медиане и скошенности.
- Словарь метрик базовой модели: MAE, RMSLE, R^2.
- 21 блок с таблицами, графиками и вердиктом.
- Сводная таблица и распределение выводов в конце.

Если вывод пустой или обрывается — проверьте, что ядро не упало на ячейке с графиком, и что установлены все библиотеки. Ноутбук не требует GPU и не обращается к сети.

4. Минимум теории, без которого не прочитать выводы

Этот раздел — не учебник статистики. Здесь собрано ровно то, что нужно, чтобы понимать фразы «p = 0,015», «ε^2 = 0,20» и «прирост MAE 2,2k», и не делать поспешных выводов.

4.1. Выборка, гипотезы и p-value

У нас есть **выборка** — 9 173 вакансии. Нас интересует **генеральная совокупность** — рынок вакансий с раскрытой зарплатой. Статистический тест отвечает на вопрос: если бы в совокупности различий не было, насколько вероятно было бы увидеть такое различие в выборке?

Формально проверяют две гипотезы:

- **H_0 (нулевая)** — «различий нет»: медианы зарплат на всех уровнях seniority одинаковы.
- **H_1 (альтернативная)** — «различия есть»: хотя бы один уровень отличается.

p-value — вероятность получить наблюдаемое (или более экстремальное) различие *при условии, что H_0 верна*. Это не вероятность того, что H_0 верна, и не вероятность «случайности результата». Маленькое p означает: данные плохо совместимы с предположением «различий нет».

Решение \ реальность	H_0 верна	H_0 неверна
Отвергли H_0	Ошибка I рода (ложноположительный результат), вероятность α	Верно
Не отвергли H_0	Верно	Ошибка II рода (пропустили эффект), вероятность β

Порог α обычно 0,05. В ноутбуке он явно не задан, но выводы читаются именно так: $p < 0{,}05$ — «различие есть», $p \geq 0{,}05$ — «данных недостаточно».

> **ОСТОРОЖНО**
> Фраза «не отвергаем H_0» не означает «H_0 верна». Она означает «различие не обнаружено». Особенно часто это путают на маленьких группах: в гипотезе 4 пара senior–executive дала p = 0,12 именно потому, что executive — всего 23 наблюдения. Это не доказательство отсутствия разницы, а нехватка данных.

> **ТЕОРИЯ**
> **Почему p зависит от размера выборки.** Чем больше данных, тем точнее оценка среднего/медианы и тем меньшие различия становятся заметны на фоне шума. При 9 000 строк даже разница в 1 % может дать $p < 0{,}001$. Поэтому рядом с p всегда нужен размер эффекта.

4.2. Какие тесты здесь используются и почему

Инструмент	Когда применяется	Что именно проверяет
Kruskal–Wallis	3+ группы, числовой признак	Все группы из одного распределения (сдвиг хотя бы у одной). Не говорит, какие именно группы различаются.
Mann–Whitney U	2 группы, числовой признак	Сдвиг распределений; устойчив к выбросам и скошенности.

Инструмент	Когда применяется	Что именно проверяет
χ^2 (хи-квадрат)	Две категориальные переменные	Связаны ли они: например, зависит ли доля remote от наличия страны.
Spearman ρ	Две числовые переменные	Монотонная связь; считается по рангам, поэтому не боится выбросов.
Pearson r	Две числовые переменные	Линейная связь; чувствителен к выбросам.
Jarque–Bera	Одна числовая переменная	Похоже ли распределение на нормальное (через асимметрию и эксцесс).

Почему не t-тест

Классический t-тест сравнивает **средние** и предполагает, что данные примерно нормальны, а дисперсии групп сопоставимы. Зарплаты скошены вправо, имеют тяжёлый хвост и разброс, который сильно отличается между странами и уровнями. На таких данных t-тест может давать неверные p-value, а среднее — не описывать «типичную» зарплату.

Ранговые тесты (Kruskal–Wallis, Mann–Whitney) работают не с самими значениями, а с их порядком. Выброс в 600 тысяч получает максимальный ранг, но не «перевешивает» всю группу. Это делает их устойчивыми и уместными для зарплат. Плата за это — гипотеза о сдвиге распределения формулируется осторожнее, чем «разница медиан».

> **ПОЧЕМУ ТАК**
> В ноутбуке почти всюду сравниваются медианы, а не средние. Медиана — это зарплата «типичной» вакансии: половина вакансий дешевле, половина дороже. Она не сдвигается от одного гигантского выброса. Среднее в таких данных полезно для суммарных бюджетов, но не для описания рынка.

Пост-хок сравнения

Kruskal–Wallis отвечает «где-то есть различие», но не «между какими группами». Поэтому после него в ноутбуке идут парные Mann–Whitney: entry–mid, mid–senior, senior–executive. Каждый парный тест — это ещё одна проверка, поэтому p умножается на число сравнений (поправка Бонферрони).

Корреляции

Pearson r измеряет, насколько точки ложатся на прямую. Spearman ρ — насколько они монотонно растут. Для «ширины вилки» и зарплаты связь нелинейная, поэтому используется Spearman. Знак показывает направление, модуль — силу: 0,1 — слабая, 0,3 — умеренная, 0,5 — заметная, 0,7+ — сильная.

> **ОСТОРОЖНО**
> Корреляция не равна причинности и не равна вкладу в модель. Два признака могут коррелировать с зарплатой, но дублировать друг друга. Именно поэтому в ноутбуке после корреляций всегда идёт сравнение моделей.

Регрессия с контролем на конфаундеры

В гипотезах 9 и 14 используется OLS:

```
smf.ols('log_salary ~ C(workplace_type, Treatment("onsite"))', data=work_df).fit(cov_type="HC1")
```

Это линейная регрессия, где `onsite` — базовая категория. Коэффициент при `remote` показывает среднюю разницу в лог-зарплате по сравнению с onsite. Перевод в проценты:

```
percent = (exp(beta) - 1) * 100
```

Формула работает потому, что при малых β `exp(β) − 1 ≈ β`, а для больших — даёт точную мультипликативную разницу. `HC1` — устойчивая к гетероскедастичности оценка стандартных ошибок: разброс зарплат не одинаков во всех группах, и обычные ошибки были бы слишком оптимистичны.

Во второй модели добавляются контроли: ATS, семейство профессий, тип занятости, период. Смысл — сравнить remote и onsite *при прочих равных*. Если премия резко падает, значит, исходная разница в основном объяснялась составом выборки.

4.3. Размер эффекта: значимо ≠ важно

p-value говорит, есть ли сигнал. Размер эффекта говорит, насколько он большой. В ноутбуке используются три меры.

ε^2 для Kruskal–Wallis

```
eps2 = (H - k + 1) / (n - k)
```

где H — статистика теста, k — число групп, n — число наблюдений. Интерпретация по Коэну: 0,01 — маленький эффект, 0,06 — средний, 0,14 — большой. Значения в ноутбуке: 0,20 для seniority, 0,33 для периода, 0,17 для семейства профессий — это большие эффекты.

Разница медиан и проценты

«Медиана remote 130k против onsite 77k» понятнее, чем «p < 0,001». Проценты удобны для сравнения признаков с разными единицами: «remote дороже на 6 % при прочих равных».

Прирост MAE

Это самая практичная мера в ноутбуке: на сколько долларов уменьшается средняя абсолютная ошибка, если добавить признак. Она отвечает не «влияет ли признак», а «сколько он приносит модели». Прирост может быть нулевым или отрицательным даже у значимого признака — это нормально.

> **РЕЗУЛЬТАТ**
> Исходный период — самый сильный категориальный признак: ε^2 = 0,33 и прирост MAE около 6,6k. ATS — ε^2 = 0,14 и прирост 1,1k. Страна — ε^2 = 0,09. То есть «сила связи» и «польза для модели» — разные вещи, и смотреть надо на обе.

4.4. Множественные проверки

В ноутбуке 21 основная гипотеза плюс десятки парных сравнений. Если проверять каждую на уровне α = 0,05, то даже при полном отсутствии эффектов примерно 5 % проверок дадут ложноположительный результат. На 21 проверке это в среднем одна «случайная находка».

Меры борьбы:

- **Поправка Бонферрони:** умножить каждое p на число проверок (или сравнивать с α/m). В ноутбуке так сделано для парных Mann–Whitney. Консервативно, но просто.
- **FDR (Benjamini–Hochberg):** контролирует долю ложных открытий среди отвергнутых гипотез; мягче Бонферрони, чаще используется в исследованиях.

- **Предрегистрация и разделение на подтверждающий/исследовательский анализ.** Если гипотезы придуманы после просмотра данных, это уже не подтверждающий тест.

> **ОСТОРОЖНО**
> Автор ноутбука честно пишет: «проверки множественные, p-value здесь — ориентир, а не окончательное доказательство». Это правильная позиция. Не превращайте p = 0,04 в заголовок «доказано», особенно если гипотеза родилась после просмотра графика.

4.5. Кросс-валидация и метрики

Модель нельзя оценивать на данных, на которых она училась: она запомнит их и покажет красивые, но бесполезные метрики. Поэтому данные делят на обучение и проверку. Один hold-out может дать шумную оценку, поэтому используют **k-fold кросс-валидацию**: данные делят на k частей, k раз обучают на k−1 частях и предсказывают оставшуюся.

```
FOLDS = list(KFold(5, shuffle=True, random_state=RANDOM_STATE).split(df))
```

В ноутбуке k = 5, перемешивание включено, `random_state = 42` для воспроизводимости. Ключевая деталь: **все модели сравниваются на одних и тех же фолдах**. Тогда разница метрик отражает вклад признака, а не случайность разбиения.

```
pred = np.full(len(X), np.nan)
for train_idx, test_idx in folds:
    fitted = fit_hgb(X.iloc[train_idx], y.iloc[train_idx])
    pred[test_idx] = predict_hgb(fitted, X.iloc[test_idx])
```

Так получается **out-of-fold предсказание** для каждой строки: оно сделано моделью, которая эту строку не видела. Дальше метрика считается по всему массиву.

> **ПОЧЕМУ 5 ФОЛДОВ И RANDOM_STATE=42**
> Пять фолдов — компромисс: при меньшем числе тестовая часть слишком мала и оценка шумная, при большем — растёт время обучения, а выигрыш в точности оценки небольшой. `random_state=42` не имеет статистического смысла: это соглашение, которое делает разбиение воспроизводимым у всех, кто запускает ноутбук. Без него повторный запуск даст другие фолды и немного другие метрики.

Метрики

Метрика	Формула / смысл	Как читать
MAE, $	Среднее абсолютной ошибки после возврата из лога: `mean(|expm1(pred) − salary_mid|)`	«В среднем модель ошибается на N долларов». Понятно бизнесу, но чувствительно к дорогим вакансиям.
RMSLE	Корень из средней квадратичной ошибки в лог-шкале	Относительная ошибка: одинаково наказывает за +10 % на 50k и на 200k. Удобно для скошенных зарплат.
R^2 (log)	Доля дисперсии лог-зарплаты, объяснённая моделью	0 — как константа, 1 — идеально; может быть отрицательным на тесте. Сравнивать R^2 можно только в одной шкале.

ТЕОРИЯ

log1p и expm1. `log1p(x) = log(1+x)` определён при x = 0 и почти не искажает большие числа. Обратное преобразование — `expm1(z) = exp(z) - 1`. Использовать `log(x)` и `exp(z)` можно, только если нулей нет; в зарплатах ноль теоретически возможен, поэтому выбран `log1p`.

ОСТОРОЖНО

R^2 в лог-шкале и R^2 в долларах — не одно и то же. В гипотезе 1 log-модель выигрывает по RMSLE, но немного проигрывает по R^2 на исходной шкале. Это не противоречие: метрики отвечают на разные вопросы. Выбор метрики — это выбор того, какая ошибка для вас дороже.

4.6. Утечка данных (leakage)

Утечка — ситуация, когда в признаки попадает информация, которой не будет в момент реального прогноза, или информация о таргете. Признак утечки — подозрительно хорошие метрики.

В ноутбуке есть три учебных примера:

1. **Гипотеза 20.** `salary_min` отлично предсказывает `salary_max` (R^2 0,92), но это не прогноз: обе величины — части одной вилки. Для «холодного» прогноза такой признак недоступен.
2. **Гипотеза 18.** 87 % описаний содержат явные суммы. TF-IDF на сыром тексте частично «подглядывает» в ответ. Поэтому автор очищает денежные паттерны и показывает, что сигнал остаётся (MAE 27,7k против 40,6k у метаданных).
3. **Гипотеза 13.** Target encoding компании нужно считать только на train-фолдах. Если закодировать всю таблицу средним по компании, в признак попадёт зарплата тестовой строки, и метрика станет нереалистично хорошей.

ПОЧЕМУ ТАК

Правило простое: **сначала разделение, потом любые вычисления, использующие таргет**. Средние, target encoding, отбор признаков, масштабирование — всё должно обучаться на train и применяться к test. В ноутбуке это реализовано в `cv_predict_target_encoding`: энкодер обучается внутри каждого фолда.

4.7. Наблюдательные данные и причинность

Данные не из эксперимента: мы не назначали компании формат работы и не случайно распределяли уровни. Поэтому любая связь может объясняться третьим фактором — **конфаундером**.

Пример из гипотезы 9. Сырые медианы: remote 130k, onsite 77k. Выглядит как «remote повышает зарплату на 45 %». Но remote-вакансии чаще в tech-компаниях, на senior-позициях, с другим ATS и периодом оплаты. После контроля на эти признаки премия падает до +5,9 %. Значит, большая часть разницы — состав выборки, а не сам формат работы.

Регрессия с контролем помогает *описать* связь при наблюдаемых признаках, но не доказывает причинность: остаются ненаблюдаемые факторы (бренд компании, грейд, стек, переговорная сила кандидата).

> **ОСТОРОЖНО**
> Формулировки «влияет», «повышает», «из-за» в отчёте лучше заменять на «связан», «ассоциирован», «при прочих равных разница составляет». Если нужен причинный вывод, нужен дизайн: эксперимент, diff-in-diff, инструментальные переменные или хотя бы явная causal-модель.

4.8. Пропуски и выбросы

Типы пропусков

- **MCAR** (missing completely at random) — пропуск не связан ни с чем. Тогда удаление строк корректно, но теряет данные.
- **MAR** (missing at random) — пропуск связан с другими наблюдаемыми признаками. Можно заполнять моделью по другим колонкам.
- **MNAR** (missing not at random) — пропуск связан с самим ненаблюдаемым значением. Самый опасный случай: нельзя игнорировать.

В ноутбуке проверяется простая, но важная мысль: пропуск `country_code` связан с платформой и форматом работы, а пропуск `seniority` — с более высокой зарплатой. Значит, пропуски не случайны. При этом отдельные индикаторы `is_missing_*` не улучшают модель, потому что информация уже присутствует в категории «Unknown».

Выбросы по Тьюки

Границы считаются по межквартильному размаху:

```
IQR = Q3 - Q1
нижняя граница = Q1 - 1.5 * IQR
верхняя граница = Q3 + 1.5 * IQR
```

Всё за границами помечается как выброс. Важно: выброс — не всегда ошибка. Это может быть реальная зарплата топ-менеджера. Поэтому в ноутбуке выбросы не удаляются, а флагируются, и отдельно проверяется подозрение на ошибку периода (гипотеза 17).

> **РЕЗУЛЬТАТ**
> Подозрительных строк всего 42 (0,5 %), но их средняя зарплата — 631k против 114k. Модель ошибается на них примерно на 500k. Исключение таких строк из обучения улучшает MAE на чистых данных лишь на ~0,3k, потому что их доля мала. Вывод: ошибки надо находить, но глобального чуда от чистки ждать не стоит.

5. Подготовка данных: что делает каждая ячейка

Первый содержательный блок ноутбука — не тесты, а конструирование признаков. Здесь важно понимать не каждую строку, а назначение шагов: что именно мы приводим к общему виду и какие новые смыслы создаём.

5.1. Загрузка и фильтрация

```
raw = load_data()
df = raw.dropna(subset=["salary_min", "salary_max"]).copy().reset_index(drop=True)
```

Строки без границ вилки удаляются: без них нельзя посчитать таргет. `reset_index(drop=True)` перенумеровывает строки, чтобы позиционные индексы совпадали с `numpy`-массивами и фолдами.

5.2. Приведение периода и валюты к долларам в год

```
PERIOD_COEF = {"day": 260, "week": 52, "month": 12, "hour": 2080, "year": 1}
CURRENCY_COEF = {"USD": 1.0, "EUR": 0.89, "CAD": 1.42, "GBP": 0.75, ...}

df["salary_min_usd"] = (
    df["salary_min"] * df["raw_period"].map(PERIOD_COEF) / df["raw_currency"].map(CURRENCY_COEF)
)
```

Логика: сначала сумму умножают на коэффициент периода (сколько таких периодов в году), затем делят на курс валюты к доллару. Например, 50 долларов в час → 50 × 2 080 = 104 000 долларов в год; 60 000 евро → 60 000 / 0,89 ≈ 67 416 долларов.

> **ОСТОРОЖНО**
> Коэффициенты — это соглашение, а не истина. 2 080 часов — это 40 часов × 52 недели, без отпуска и праздников. Для почасовых вакансий годовая сумма может быть завышена. Курсы зафиксированы на дату сбора. Если вы переносите код на другие данные, коэффициенты и курсы нужно обновить и задокументировать.

5.3. Таргет и производные величины

```
df["salary_mid"] = (df["salary_min_usd"] + df["salary_max_usd"]) / 2
df["log_salary"] = np.log1p(df["salary_mid"])
df["spread"] = df["salary_max_usd"] - df["salary_min_usd"]
df["spread_pct"] = df["spread"] / df["salary_mid"]
```

`salary_mid` — таргет; `log_salary` — тот же таргет в лог-шкале, на нём обучается большинство моделей; `spread` — абсолютная ширина вилки, `spread_pct` — относительная. Последние две нужны для гипотезы 3.

> **ПОЧЕМУ ТАК**
> Середина вилки — компромисс между min и max. Она устойчивее min (не занижена для вакансий, где нижняя граница — формальность) и не раздута, как max. Кроме того, как показала гипотеза 2, min и max почти коллинеарны, поэтому отдельные модели для них дублируют друг друга.

5.4. Флаги выбросов и подозрительного периода

```
def iqr_bounds(values):
    q1, q3 = values.quantile([0.25, 0.75])
    iqr = q3 - q1
    return q1 - 1.5 * iqr, q3 + 1.5 * iqr

for col in ["salary_min_usd", "salary_max_usd"]:
    low, high = iqr_bounds(df[col])
    df[f"outlier_{col}"] = (df[col] < low) | (df[col] > high)
```

```
df["outlier_any"] = df["outlier_salary_min_usd"] | df["outlier_salary_max_usd"]
df["period_suspect"] = df["outlier_any"] & df["raw_period"].ne("year")
```

Флаг `period_suspect` объединяет два условия: сумма выглядит выбросом *и* период не годовой. Гипотеза: возможно, годовая сумма была ошибочно записана как почасовая или наоборот. Такие строки не удаляются, а помечаются — их влияние проверяется в гипотезе 17.

5.5. Индикаторы пропусков

```
MISSING_FIELDS = ["seniority", "workplace_type", "country_code", "language",
                  "department", "employment_type", "region", "city"]
for col in MISSING_FIELDS:
    df[f"is_missing_{col}"] = df[col].isna().astype(int)
```

Для каждого поля создаётся бинарный признак «здесь пропуск». Это нужно, чтобы проверить гипотезу 19: сам факт отсутствия данных может быть сигналом.

5.6. Базовая группа категориальных признаков

```
BASE = ["ats", "employment_type", "workplace_type", "country_code", "salary_source", "raw_period"]
for col in BASE:
    df[col] = df[col].fillna("Unknown").astype(str)
```

Пропуски заменяются на строку `"Unknown"`, а не на моду или среднее. Причина: пропуск не случаен и может нести информацию. Категория «нет данных» — это отдельное состояние, а не «средний ATS».

> **ТЕОРИЯ**
> Заполнение категориального пропуска модой — популярный, но часто вредный приём. Оно смешивает «нет данных» с самой частой категорией и скрывает структуру пропуска. Если пропуск информативен, лучше явная категория `"Unknown"` или отдельный флаг.

5.7. Семейство профессии из названия

```
FAMILY_PATTERNS = {
    "engineering": r"engineer|developer|software|...",
    "sales": r"\bsales\b|account executive|...",
    ...
}
def job_family(title):
    text = str(title).lower()
    for family, pattern in FAMILY_PATTERNS.items():
        if re.search(pattern, text):
            return family
    return "other"
df["job_family"] = df["title"].map(job_family)
```

Это правило-эвристика: если в названии встретилось слово из шаблона, вакансия относится к семейству. Порядок словаря важен: первое совпадение выигрывает. Например, «Data Engineer» попадёт в engineering.

ОСТОРОЖНО

Эвристика ошибается: «Sales Engineer» может уйти в engineering, «Product Designer» — в design_product, а 34 % вакансий остаются в `other`. Это приемлемо для исследовательского анализа, но для продакшена лучше обучаемый классификатор по title или эмбеддинги. Автор ноутбука сам это отмечает.

5.8. Штат из географии

```
def extract_state(row):
    text = f"{row.get('location', '')}, {row.get('region', '')}"
    ...  # поиск полного названия штата, затем двухбуквенного кода
    return None

df["state_model"] = np.where(df["country_code"].eq("US"), df["state"].fillna("Unknown"), "Unknown")
```

Штат извлекается только для США, потому что для других стран такая детализация либо отсутствует, либо несопоставима. Полные названия («California») переводятся в коды («CA»), затем коды ищутся в тексте. Покрытие — около 82 % американских вакансий.

5.9. Даты

```
df["posted"] = pd.to_datetime(df["posted_at"], utc=True)
df["lag_hours"] = (df["first_seen"] - df["posted"]).dt.total_seconds() / 3600
df["posted_dow"] = df["posted"].dt.day_name()
df["posted_hour"] = df["posted"].dt.hour
df["days_since_start"] = (df["posted"] - df["posted"].min()).dt.total_seconds() / 86400
```

Из дат извлекаются день недели, час, задержка до первого обнаружения и «возраст» вакансии относительно начала сбора. Гипотеза 21 проверяет, есть ли в этом сигнал.

5.10. Единые фолды

```
FOLDS = list(KFold(5, shuffle=True, random_state=RANDOM_STATE).split(df))
```

Фолды создаются один раз и переиспользуются. Это принципиально: если для каждой гипотезы генерировать новое разбиение, разница MAE будет частично случайной. С общими фолдами сравнение становится парным.

ОСТОРОЖНО

Случайные фолды подходят для сравнения моделей на одних данных, но не для честного прогноза «в будущее». Если бы данные охватывали несколько месяцев, нужно было бы использовать временное разбиение (train — прошлое, test — будущее). Здесь окно всего неделя, поэтому random KFold допустим, но это ограничение стоит проговаривать.

6. Вспомогательные функции: «двигатель» ноутбука

После подготовки данных идут десять небольших функций. Они избавляют от копирования кода и, что важнее, фиксируют методику: все гипотезы считаются одинаково. Разберём каждую.

6.1. Форматирование p-value

```
def pfmt(p):
    if p < 1e-300: return "<1e-300"
    if p < 1e-4:  return f"{p:.1e}"
    return f"{p:.3f}"
```

Нужна, чтобы в таблицах не появлялись числа вроде `3.27e-117` и чтобы крошечные p не выглядели как ноль. «p < 1e-300» — это не ноль, а «меньше любой разумной точности».

6.2. Метрики

```
def metrics(pred_log, actual):
    usd = np.expm1(pred_log)
    return {
        "MAE, $": int(round(mean_absolute_error(actual, usd))),
        "RMSLE": round(float(np.sqrt(np.mean((pred_log - np.log1p(actual)) ** 2))), 3),
        "R2 (log)": round(float(r2_score(np.log1p(actual), pred_log)), 3),
    }
```

Функция принимает предсказания в лог-шкале, возвращает три метрики: MAE в долларах (после `expm1`), RMSLE и R^2 в лог-шкале. Важно, что все модели в ноутбуке предсказывают лог — так метрики сопоставимы.

6.3. Kruskal–Wallis с размером эффекта

```
def kruskal_table(data, value, group, min_n=20):
    d = data.dropna(subset=[value, group]).copy()
    counts = d.groupby(group).size()
    keep = counts[counts >= min_n].index
    d = d[d[group].isin(keep)]
    groups = [g[value].to_numpy() for _, g in d.groupby(group)]
    H, p = stats.kruskal(*groups)
    n, k = len(d), len(groups)
    eps2 = (H - k + 1) / (n - k) if n > k else np.nan
    table = d.groupby(group)[value].agg(["median", "size"]).sort_values("median", ascending=False)
    return {"H": H, "p": p, "eps2": eps2, "table": table, "n": n, "k": k}
```

Что важно в этой функции:

- `dropna` — тест не принимает пропуски.
- `min_n` — группы меньше порога отбрасываются, иначе тест опирается на единичные наблюдения и даёт нестабильные p.
- `eps2` — размер эффекта, который не зависит от размера выборки.
- Таблица отсортирована по медиане — удобно сразу увидеть порядок групп.

6.4. Парные сравнения с поправкой

```
def pairwise_mw(data, value, group, pairs):
    rows = []
    for a, b in pairs:
        x = data.loc[data[group].eq(a), value].dropna()
        y = data.loc[data[group].eq(b), value].dropna()
        _, p = stats.mannwhitneyu(x, y)
```

```
            rows.append({... "p": p, "p (Bonferroni)": min(1.0, p * len(pairs))})
    return pd.DataFrame(rows)
```

Для каждой пары считается Mann–Whitney, затем p умножается на число пар. Это и есть поправка Бонферрони: мы «платим» за каждую дополнительную проверку.

6.5. Модель HistGradientBoosting

```
def make_hgb():
    return HistGradientBoostingRegressor(
        max_iter=300, learning_rate=0.05, max_leaf_nodes=31,
        l2_regularization=1.0, random_state=RANDOM_STATE,
        early_stopping=False, categorical_features=None,
    )
```

HistGradientBoosting — градиентный бустинг на деревьях, оптимизированный для табличных данных. Он строит много неглубоких деревьев, каждое следующее исправляет ошибки предыдущих. Гиперпараметры:

Параметр	Зачем нужен
`max_iter=300`	Число деревьев. Больше — точнее на train, но дольше и риск переобучения.
`learning_rate=0.05`	Вклад каждого дерева. Меньше — плавнее и устойчивее, но нужно больше деревьев.
`max_leaf_nodes=31`	Сложность дерева. Ограничивает взаимодействия признаков.
`l2_regularization=1.0`	Штраф за большие веса листьев; борется с переобучением.
`early_stopping=False`	Отключён, чтобы все модели обучались одинаково и сравнение было честным.

ПОЧЕМУ ТАК

Бустинг выбран как «рабочая лошадка», а не как лучшая возможная модель. Он хорошо ловит нелинейности и взаимодействия, не требует масштабирования, устойчив к выбросам и умеет работать с категориями. Для сравнения гипотез важна не максимальная точность, а стабильность и одинаковая обработка признаков.

```
def fit_hgb(X_train, y_train):
    cats = [c for c in X_train.columns if not pd.api.types.is_numeric_dtype(X_train[c])]
    nums = [c for c in X_train.columns if c not in cats]
    encoder = OrdinalEncoder(handle_unknown="use_encoded_value", unknown_value=-1)
    cat_part = encoder.fit_transform(X_train[cats].astype(str)) if cats else np.empty((len(X_train), 0))
    num_part = X_train[nums].to_numpy(dtype=float)
    mask = np.array([True] * len(cats) + [False] * len(nums))
    model = make_hgb()
    model.set_params(categorical_features=mask)
    model.fit(np.hstack([cat_part, num_part]), y_train)
    return model, encoder, cats, nums
```

Здесь категории кодируются порядковыми номерами, но модели явно сообщается, какие колонки категориальные (маска `categorical_features`). Внутри она обрабатывает их как категории, а не как числа. `handle_unknown="use_encoded_value", unknown_value=-1` спасает, если в тесте встретилась категория, которой не было в train.

6.6. Кросс-валидация с дополнительными признаками

```
def cv_predict(X, y, folds=FOLDS, extra=None):
    X = X.copy()
    if extra is not None:
        for key, values in extra.items():
            X[key] = np.asarray(values)
    pred = np.full(len(X), np.nan)
    for train_idx, test_idx in folds:
        fitted = fit_hgb(X.iloc[train_idx], y.iloc[train_idx])
        pred[test_idx] = predict_hgb(fitted, X.iloc[test_idx])
    return pred
```

Параметр `extra` позволяет добавить признак к базовому набору, не переписывая цикл. Именно так проверяется вклад `job_family`, `seniority_pred`, дат и флагов пропусков.

6.7. Target encoding без утечки

```
def cv_predict_target_encoding(X, y, column, folds=FOLDS):
    groups = df[column].reset_index(drop=True)
    pred = np.full(len(X), np.nan)
    for train_idx, test_idx in folds:
        encoder = TargetEncoder(cv=KFold(5, shuffle=True, random_state=RANDOM_STATE), smooth="auto")
        X_train = X.iloc[train_idx].copy()
        X_test = X.iloc[test_idx].copy()
        X_train["__target_enc"] = encoder.fit_transform(
            groups.iloc[train_idx].to_frame(), y.iloc[train_idx]).ravel()
        X_test["__target_enc"] = encoder.transform(groups.iloc[test_idx].to_frame()).ravel()
        fitted = fit_hgb(X_train, y.iloc[train_idx])
        pred[test_idx] = predict_hgb(fitted, X_test)
    return pred
```

Target encoding заменяет категорию (например, компанию) средним таргетом по этой категории. Компаний почти 4 000, one-hot дал бы тысячи разреженных колонок, а target encoding — одну числовую. Внутренний `cv=KFold(5)` считает кодировку по частям train, чтобы не подглядывать в таргет; `smooth="auto"` сглаживает средние для редких компаний к общему среднему.

> **ОСТОРОЖНО**
> Target encoding — чемпион по утечкам. Если посчитать средний таргет по всей таблице и потом разбить на фолды, модель получит подсказку и покажет завышенное качество. В продакшене энкодер обучают на исторических данных и аккуратно применяют к новым категориям (с запасным значением).

6.8. Журнал выводов

```
SUMMARY = []
def add_summary(number, hypothesis, method, result, verdict):
    SUMMARY.append({"№": number, "Гипотеза": hypothesis, ...})

BASE_PRED = cv_predict(df[BASE], df.log_salary)
BASE_METRICS = metrics(BASE_PRED, df.salary_mid)
```

`add_summary` — это не статистика, а инженерная привычка: каждая проверка сразу записывается в сводку с номером, методом, результатом и вердиктом. В конце из списка собирается таблица. Такой журнал спасает от ситуации «пять графиков посмотрел, а что решил — забыл».

`BASE_PRED` — out-of-fold предсказания базовой модели на шести категориальных признаках. Это точка отсчёта: прирост MAE во всех гипотезах считается относительно неё.

> **РЕЗУЛЬТАТ**
> Базовая модель ошибается в среднем на 39,9 тысячи долларов. Дальше каждый признак оценивается по тому, насколько он уменьшает эту ошибку. Такой «долларовый» язык делает выводы понятными даже без статистического образования.

7. Разбор 21 гипотезы

Это ядро методички. Для каждой гипотезы: зачем она нужна, как её проверяли, что получилось, как это понимать и где подстерегает ошибка. Числа взяты из выводов ноутбука; они могут немного меняться при повторном запуске из-за версий библиотек и порядка операций, но порядок величин устойчив.

> **КАК УСТРОЕНА КАРТОЧКА**
> **Вопрос** — проверяемое утверждение. **Как проверяли** — данные, тест, модель. **Что получилось** — ключевые числа. **Как понимать** — интерпретация и связь с теорией. **Чему учит** — переносимый приём или предупреждение. Внизу — вердикт автора ноутбука.

7.1. Таргет: гипотезы 1–3

1 Предсказывать логарифм зарплаты, а не саму зарплату

ВОПРОС

Улучшит ли модель переход от `salary_mid` к `log1p(salary_mid)`?

КАК ПРОВЕРЯЛИ

Сначала описательно: коэффициент асимметрии (skew), тест Jarque–Bera на нормальность, QQ-графики. Затем одна и та же модель (`HistGradientBoosting`) обучалась дважды — на исходной зарплате и на логарифме — на одних и тех же 5 фолдах. Метрики пересчитывались в доллары через `expm1`.

ЧТО ПОЛУЧИЛОСЬ

Skew падает с 3,56 до −0,08, то есть распределение становится почти симметричным. RMSLE улучшается с 0,738 до 0,451. MAE тоже немного снижается. При этом R^2 на исходной шкале у лог-модели чуть ниже: 0,279 против 0,302.

КАК ПОНИМАТЬ

Логарифм сжимает правый хвост и превращает процентные различия в равные шаги. Модель перестаёт «гоняться» за дорогими вакансиями и лучше предсказывает типичные. Jarque–Bera формально отвергает нормальность в обоих случаях (на 9 000 наблюдений любой тест это сделает), но skew и QQ-plot показывают, что лог-шкала гораздо ближе к симметрии.

ЧЕМУ УЧИТ

Выбор шкалы таргета — это не косметика, а выбор того, какую ошибку вы считаете важной. Лог-шкала оптимизирует относительную ошибку, исходная — абсолютную. Кроме того, после `expm1` предсказание смещено: медиана лог-нормального распределения не равна среднему. Для MAE это не критично, но для оценки суммарного бюджета нужна поправка на смещение.

Подтверждена (с оговоркой)

2 Один таргет — середина вилки, а не min и max по отдельности

ВОПРОС

Можно ли ограничиться одним числом на вакансию, если вилка состоит из двух границ?

КАК ПРОВЕРЯЛИ

Посчитали корреляцию Пирсона и Спирмена между `salary_min_usd` и `salary_max_usd`. Затем обучили три одинаковые модели — на логарифме min, середины и max — и сравнили MAE, RMSLE и R^2.

ЧТО ПОЛУЧИЛОСЬ

Pearson 0,944; Spearman 0,958 — границы почти коллинеарны. Модели для min, mid и max дают близкие ошибки, а R^2 у середины максимален (0,474).

КАК ПОНИМАТЬ

Если две величины почти линейно связаны, отдельная модель для второй не добавляет информации. Середина — удобный компромисс: она не занижена, как нижняя граница (иногда указывают формальный минимум), и не раздута, как верхняя. Зная середину и относительную ширину, границы можно восстановить приблизительно.

ЧЕМУ УЧИТ

Прежде чем строить несколько моделей, проверьте корреляцию таргетов. Часто одна модель плюс производные признаки решают задачу лучше и проще. Но выбор середины — не универсальное правило: если бизнес-вопрос «какая минимальная зарплата указана в вакансии», нужен именно min.

Подтверждена

3 Ширина вилки — отдельный сигнал

ВОПРОС

Несёт ли `spread` информацию сверх уровня зарплаты, и можно ли её предсказать?

КАК ПРОВЕРЯЛИ

Spearman между абсолютной/относительной шириной и зарплатой; Kruskal–Wallis по периодам, уровням и типу занятости; две модели — на `spread_pct` и на `log1p(spread)` — с той же кросс-валидацией.

ЧТО ПОЛУЧИЛОСЬ

Абсолютная ширина сильно растёт с зарплатой: $\rho = 0{,}75$. Относительная — слабее: $\rho = 0{,}24$. Предсказуемость относительной ширины низкая: $R^2 = 0{,}08$. Различия по периоду и типу занятости статистически значимы.

КАК ПОНИМАТЬ

Абсолютная ширина в основном повторяет уровень: дорогие вакансии имеют более широкие вилки просто потому, что 10 % от 200k больше, чем 10 % от 50k. Относительная ширина — уже другой смысл: насколько компания готова торговаться. Она плохо предсказывается по метаданным, но может быть полезна для построения интервалов, а не для точечного прогноза.

ЧЕМУ УЧИТ

Низкий R^2 не всегда означает «признак бесполезен». Если задача — не предсказать число, а оценить неопределённость, слабый сигнал тоже ценен. И наоборот: высокий ρ не означает, что признак нужен в модели — он может дублировать таргет.

Частично подтверждена

7.2. Роль и уровень: гипотезы 4–7

4 Уровень позиции положительно влияет на зарплату

ВОПРОС

Растёт ли зарплата при переходе entry → mid → senior → executive?

КАК ПРОВЕРЯЛИ

Kruskal–Wallis по `seniority` (только заполненные строки, группы от 10 наблюдений), затем парные Mann–Whitney для соседних уровней с поправкой Бонферрони. На графике — боксплоты в лог-шкале и линия общей медианы.

ЧТО ПОЛУЧИЛОСЬ

Медианы: entry 50,1k, mid 61,6k, senior 97,5k, executive 135k. Различия значимы, $\varepsilon^2 = 0{,}20$ — большой эффект. Пара senior–executive незначима ($p = 0{,}12$), потому что executive всего 23 наблюдения.

КАК ПОНИМАТЬ

Направление и порядок уровней устойчивы. Но `seniority` заполнен лишь у 7 % вакансий, и это не случайная подвыборка: вероятно, его указывают компании с более зрелым HR-процессом. Поэтому медианы нельзя переносить на весь рынок без оговорки.

ЧЕМУ УЧИТ

Значимость и размер эффекта смотрят вместе: p может быть маленьким, а эффект — ничтожным, или наоборот. И всегда проверяйте размер наименьшей группы: незначимая пара может быть просто недоисследованной, а не «одинаковой».

Подтверждена

5 Уровень можно восстановить из `title`, несмотря на 93 % пропусков

ВОПРОС

Можно ли предсказать seniority по названию вакансии и помогает ли это модели?

КАК ПРОВЕРЯЛИ

TF-IDF по названиям (униграммы и биграммы) → логистическая регрессия с `class_weight="balanced"`. Стратифицированная 5-fold кросс-валидация на строках с известным уровнем. Метрики: accuracy, balanced accuracy, матрица ошибок. Затем предсказанный уровень добавлялся как признак в модель зарплаты.

ЧТО ПОЛУЧИЛОСЬ

Accuracy 0,61 против 0,44 у мажоритарного класса; balanced accuracy 0,53. Предсказанный уровень упорядочивает зарплаты: от 63k до 180k. Прирост MAE поверх семейства профессий: 37,7k → 34,6k. Но mid, senior и internship путаются часто.

КАК ПОНИМАТЬ

В названиях действительно есть сигнал: слова «Senior», «Lead», «Intern» информативны. Однако 61 % точности на пяти классах — это умеренно: модель лучше случайной, но не заменяет разметку. Balanced accuracy ниже accuracy, потому что редкие классы (internship, executive) предсказываются плохо.

ЧЕМУ УЧИТ

Accuracy обманчива при дисбалансе классов: всегда сравнивайте с долей мажоритарного класса и смотрите balanced accuracy и матрицу ошибок. И помните про тонкую утечку: классификатор

обучался на всех размеченных строках, а затем его предсказания использовались как признак для тех же строк в кросс-валидации. Для строк с известным уровнем это оптимистично; честнее обучать классификатор внутри каждого фолда.

Частично подтверждена

6 Семейство профессии значимо

ВОПРОС

Различаются ли зарплаты между группами профессий, и помогает ли `job_family` модели?

КАК ПРОВЕРЯЛИ

Kruskal–Wallis по `job_family` (группы от 50 наблюдений), боксплоты в лог-шкале, затем добавление признака в базовую модель и сравнение MAE на общих фолдах.

ЧТО ПОЛУЧИЛОСЬ

$\varepsilon^2 = 0{,}17$ — большой эффект. Медианы: legal, design и engineering около 150k и выше; admin, education, customer — ниже 70k. Прирост MAE около 2,2k. При этом 34 % вакансий попали в `other`.

КАК ПОНИМАТЬ

Профессия — сильный и содержательный признак. Но `job_family` — грубая эвристика по названию: она не различает грейды внутри семьи и теряет треть вакансий. Для исследовательского вывода этого достаточно, для продукта — нет.

ЧЕМУ УЧИТ

Признак, собранный регуляркой, может дать реальный прирост — но качество эвристики надо измерять (доля `other`, ручная проверка примеров). Если категория «другое» слишком большая, модель теряет информацию.

Подтверждена

7 `department` полезен там, где заполнен (59 %)

ВОПРОС

Добавляет ли подразделение компании информацию о зарплате?

КАК ПРОВЕРЯЛИ

Взяли строки с заполненным `department`, редкие значения (меньше 30 наблюдений) объединили в «Other», затем Kruskal–Wallis и сравнение модели с признаком и без на фолдах, построенных только по этой подвыборке.

ЧТО ПОЛУЧИЛОСЬ

Различия сильные: Engineering 185k, Product 183k, Retail 39k. Прирост MAE около 1,1k. Поле имеет 2 202 уникальных значения, заполнено у 59 %. Медиана зарплаты при пропуске 82k против 115k при заполнении.

КАК ПОНИМАТЬ

Подразделение — хороший прокси функции и уровня, но только внутри компаний, где его заполняют. Пропуск связан с зарплатой, поэтому «Unknown» — не нейтральная категория, а отдельный сигнал. Редкие значения обязательно нужно группировать, иначе признак превращается в почти уникальный идентификатор.

ЧЕМУ УЧИТ

Для категорий с тысячами значений нужна редкая группировка или target encoding. И нельзя оценивать пользу признака на всей выборке, если он заполнен частично: сравнение должно идти на сопоставимой подвыборке.

Подтверждена (на подвыборке)

7.3. География и формат работы: гипотезы 8–11

8 `country_code` значимо влияет на зарплату

ВОПРОС

Отличаются ли зарплаты между странами?

КАК ПРОВЕРЯЛИ

Kruskal–Wallis по `country_code` для стран с минимум 30 наблюдениями; боксплоты в лог-шкале; размер эффекта ε^2.

ЧТО ПОЛУЧИЛОСЬ

$\varepsilon^2 = 0{,}09$ — средний/большой эффект. США 107,5k, Германия 78,9k, Франция 40,3k, Италия 44,5k.

КАК ПОНИМАТЬ

Страна — один из сильных признаков, но разрыв объясняется не только рынком. В США больше tech- и senior-вакансий, другой состав платформ, другая валюта и стоимость жизни. Это совместный сигнал «страна + роль + компания», а не чистая поправка на стоимость жизни.

ЧЕМУ УЧИТ

Географический признак почти всегда коррелирует с составом выборки. Прежде чем говорить «в стране X платят больше», проверьте, не объясняется ли это профессией и уровнем. Для честного сравнения нужен контроль или сопоставление внутри одинаковых ролей.

Подтверждена

9 remote > hybrid > onsite

ВОПРОС

Платят ли удалённые вакансии больше, и сохраняется ли разница после контроля на состав выборки?

КАК ПРОВЕРЯЛИ

Kruskal–Wallis и парные Mann–Whitney; затем две OLS-модели на лог-зарплате: без контролей и с контролем на ATS, семейство профессий, тип занятости и период. Базовая категория — onsite. Стандартные ошибки HC1. Эффект переведён в проценты: `exp(β) - 1`.

ЧТО ПОЛУЧИЛОСЬ

Сырые медианы: remote 130k, hybrid 117,6k, onsite 77k. Без контроля remote выглядит дороже на 45 %. После контроля премия падает до +5,9 % ($p = 0{,}015$), hybrid — до +3,0 % и становится незначимой ($p = 0{,}19$).

КАК ПОНИМАТЬ

Почти вся исходная разница — это состав выборки: удалённые вакансии чаще встречаются в tech-компаниях, на senior-позициях и с другим типом оплаты. Сам по себе формат работы — слабый признак. Остаточные +6 % можно трактовать как «небольшая ассоциация при прочих наблюдаемых равных», но не как причинный эффект.

ЧЕМУ УЧИТ

Это главный урок ноутбука про конфаундеры. Сравнение «среднее по группам» почти всегда смешано с составом групп. Контроль на наблюдаемые признаки уменьшает смещение, но не убирает его полностью. И $p = 0{,}015$ после множества проверок — хрупкое доказательство: не стройте на нём сильных утверждений.

Частично подтверждена

10 Внутри США город и штат значимы

ВОПРОС

Объясняет ли география внутри страны часть разброса зарплат?

КАК ПРОВЕРЯЛИ

Из `location` и `region` регуляркой извлекли штат, проверили покрытие. Kruskal–Wallis по штатам (от 30 наблюдений). Затем на подвыборке США сравнили модель без штата и со штатом на общих фолдах.

ЧТО ПОЛУЧИЛОСЬ

Штат извлекается для 82 % американских вакансий. ε^2 = 0,12. Калифорния 145k, Нью-Йорк 129k, Теннесси 58k. Прирост MAE около 0,9k.

КАК ПОНИМАТЬ

Внутри страны география действительно полезна, но эффект скромнее, чем у периода или компании. Штат — прокси стоимости жизни и концентрации отраслей. Город отдельно не проверялся: значений слишком много, и шум превысил бы сигнал.

ЧЕМУ УЧИТ

Признак с высоким покрытием и понятной интерпретацией стоит добавлять даже при небольшом приросте. Но не каждый уровень детализации полезен: «город» может дать сотни редких категорий и переобучение вместо знания.

Подтверждена

11 Пропуск `country_code` — сигнал, а не случайность

ВОПРОС

Отличаются ли вакансии без страны от вакансий со страной, и является ли пропуск информативным?

КАК ПРОВЕРЯЛИ

Сравнили медианы и размеры групп; χ^2 для связи пропуска с форматом работы и ATS; Mann–Whitney внутри remote-вакансий, чтобы отделить эффект формата.

ЧТО ПОЛУЧИЛОСЬ

Медиана без страны 129k против 107,5k у США. Среди вакансий без страны 47 % remote (против 15 % со страной) и 90 % приходят через Greenhouse (против 24 %). Но внутри Greenhouse-remote медиана без страны уже ниже: 139k против 158,5k у США.

КАК ПОНИМАТЬ

Пропуск — не случайное отсутствие данных, а маркер канала и формата: глобальные remote-вакансии часто публикуются без страны. «Премия за пропуск» на уровне всей выборки — артефакт состава. Внутри сопоставимой группы направление меняется.

ЧЕМУ УЧИТ

Пропуск можно использовать как признак, но интерпретировать его надо через механизм возникновения. Это классический пример MNAR/MAR: отсутствие значения связано с самим объектом. И всегда проверяйте эффект внутри подгрупп — средние по всей выборке могут обманывать (парадокс Симпсона).

Частично подтверждена

7.4. Компания и платформа: гипотезы 12–14

12 `ats` — сильный прокси типа компании

ВОПРОС

Связана ли платформа публикации с зарплатой, и нужна ли она модели?

КАК ПРОВЕРЯЛИ

Kruskal–Wallis по `ats`; сравнение модели с ATS и без; permutation importance на hold-out 20 %: признак перемешивают и смотрят, насколько падает качество.

ЧТО ПОЛУЧИЛОСЬ

ε^2 = 0,14. Медианы: Ashby 151k, Greenhouse 117,5k, Workday 83k, Recruitee 51,2k. Удаление ATS ухудшает MAE на 1,1k. По permutation importance ATS — третий после периода и страны.

КАК ПОНИМАТЬ

ATS не «влияет» на зарплату. Это маркер типа компании: Ashby и Greenhouse чаще выбирают стартапы и tech, Workday — крупные корпорации. Признак полезен для прогноза, но его интерпретация — «через какую платформу наняли», а не «сколько платят за платформу».

ЧЕМУ УЧИТ

Permutation importance показывает вклад признака в конкретную модель, а не «истинную важность». Коррелированные признаки делят вклад: если убрать ATS, его информацию частично подхватят другие. Поэтому важность надо читать вместе с экспериментом «убрали признак — как изменилась метрика».

Подтверждена

13 `company` / `company_id` улучшают прогноз при target encoding

ВОПРОС

Можно ли использовать компанию как признак, если компаний почти 4 000?

КАК ПРОВЕРЯЛИ

Target encoding внутри каждого фолда: категория заменяется средним лог-таргетом по train, с внутренней кросс-валидацией и сглаживанием. Отдельно проверили `company` и `company_id`.

ЧТО ПОЛУЧИЛОСЬ

MAE падает с 39,9k до 37,2k для обоих вариантов — примерно на 7 %. Компаний 3 970, из них 1 274 встречаются один раз. `company_id` чуть точнее, потому что различает подразделения одной компании.

КАК ПОНИМАТЬ

Компания — один из самых полезных признаков: она кодирует отрасль, размер, уровень найма и щедрость. Но именно поэтому она опасна: для редких компаний среднее по 1–2 вакансиям — это почти таргет. Сглаживание тянет такие значения к общему среднему, а внутренняя CV не даёт энкодеру подсмотреть в свой же фолд.

ЧЕМУ УЧИТ

Target encoding — стандартный способ работать с высококардинальными категориями, но только с тремя предосторожностями: обучение внутри train, сглаживание редких категорий и запасное значение для новых. Без них метрика будет красивой, а модель — бесполезной.

Подтверждена

14 `salary_source` — признак качества данных, а не рынка

ВОПРОС

Означает ли разница между зарплатами «из ATS» и «из описания» реальную рыночную разницу?

КАК ПРОВЕРЯЛИ

Медианы по источнику; χ^2 связи источника с ATS; две OLS-модели: без контролей и с контролем на ATS и период; доля выбросов по источнику.

ЧТО ПОЛУЧИЛОСЬ

Без контроля `description` выглядит на 14 % дешевле `ats`. После контроля эффект исчезает: −1,3 %, p = 0,40. Источник почти детерминирован платформой: Workday — 100 % из описания, Greenhouse — 56 %, Ashby — 23 %. В ats-выборке больше выбросов: 4,4 % против 2,8 %.

КАК ПОНИМАТЬ

Это не рыночный сигнал, а след способа сбора: разные платформы по-разному отдают зарплату. Признак полезен для диагностики качества и для понимания, откуда взялись числа, но интерпретировать его как «зарплата из описания ниже» нельзя.

ЧЕМУ УЧИТ

Прежде чем радоваться значимому признаку, спросите: «а не является ли он артефактом пайплайна?». Переменные источника, версии парсера, даты выгрузки часто объясняют больше, чем рынок. Их место — в мониторинге качества, а не в объяснении зарплат.

Подтверждена

7.5. Занятость и период: гипотезы 15–17

15 `employment_type` значим

ВОПРОС

Отличаются ли зарплаты между полной, частичной занятостью, контрактом и временной работой?

КАК ПРОВЕРЯЛИ

Kruskal–Wallis, парные Mann–Whitney, сравнение модели с признаком и без него.

ЧТО ПОЛУЧИЛОСЬ

ε^2 = 0,09. Медианы: full-time 100k, contract 81k, temporary 57,2k, part-time 42,1k. Прирост MAE небольшой — около 0,3k.

КАК ПОНИМАТЬ

Различия значимы и содержательны, но после учёта периода и ATS вклад почти исчезает: тип занятости сильно коррелирует с почасовой оплатой и платформой. Это типичный случай «значимо, но избыточно».

ЧЕМУ УЧИТ

Статистическая значимость не гарантирует прироста в модели. Если признак дублирует другой, его вклад может быть близок к нулю. Проверяйте incremental value, а не только p-value.

Подтверждена (слабый прирост)

16 Исходный `salary_period` — информативный признак

ВОПРОС

Нужно ли сохранять исходный период оплаты, если все суммы уже приведены к году?

КАК ПРОВЕРЯЛИ

Kruskal–Wallis по `raw_period`; модель без этого признака; анализ состава по типу занятости.

ЧТО ПОЛУЧИЛОСЬ

$\varepsilon^2 = 0{,}33$ — самый большой эффект среди категориальных признаков. Без `raw_period` MAE растёт с 39,9k до 46,6k. При этом `hour` — это в основном почасовые и частичные роли (53 % full-time, 17 % part-time, 21 % без типа занятости), а `year` — офисные.

КАК ПОНИМАТЬ

Период — не просто единица измерения. Он кодирует формат оплаты и тип роли: почасовая работа часто ниже по годовой сумме, но это другой механизм. Поэтому после нормализации признак не выбрасывают — он остаётся полезным.

ЧЕМУ УЧИТ

При приведении единиц измерения не удаляйте исходную единицу: она может нести информацию о процессе. Но интерпретируйте её как «формат оплаты + тип роли», а не как «рыночную ставку». И помните, что коэффициенты пересчёта (2 080 часов) — это допущение.

Подтверждена

17 Ошибки нормализации периода ухудшают модель

ВОПРОС

Что делать со строками, где сумма выглядит выбросом, а период не годовой?

КАК ПРОВЕРЯЛИ

Определили 42 подозрительные строки. Сравнили три варианта обучения: (A) на всех строках, (B) без подозрительных, (C) на всех плюс флаг `period_suspect`. Оценка — MAE на чистых тестовых строках и отдельно на подозрительных.

ЧТО ПОЛУЧИЛОСЬ

Подозрительных строк 0,5 %, но средняя зарплата у них 631k против 114k, а ошибка модели — около 500k. Исключение из обучения улучшает MAE на чистых данных всего на ~0,3k (0,8 %); флаг даёт примерно тот же эффект.

КАК ПОНИМАТЬ

Даже грубая ошибка в 0,5 % строк почти не двигает среднюю метрику, потому что её вклад мал. Но если смотреть на этих клиентов отдельно, ошибка катастрофическая. Поэтому чистка важна локально, а не как способ улучшить общий MAE.

ЧЕМУ УЧИТ

Оценивайте модель не только по среднему: смотрите на хвосты и подгруппы. И помните, что флаг `period_suspect` построен по `salary_min/max` — в «холодном» прогнозе, где зарплата неизвестна, его не будет. Это диагностический признак, а не продакшн-фича.

Частично подтверждена

7.6. Текст и пропуски: гипотезы 18–19

18 `description` содержит сигнал о зарплате

ВОПРОС

Можно ли предсказывать зарплату по тексту описания, и не является ли это подглядыванием в ответ?

КАК ПРОВЕРЯЛИ

TF-IDF (до 20 000 признаков, униграммы и биграммы, `min_df=3`, `sublinear_tf`, английские стоп-слова) → Ridge. Четыре варианта: только метаданные, сырой текст, текст с замаскированными денежными упоминаниями, метаданные + текст. Оценка — та же 5-fold CV.

ЧТО ПОЛУЧИЛОСЬ

MAE: метаданные 40,6k, сырой текст 27,1k, очищенный текст 27,7k, совместная модель 25,7k. 87 % описаний содержат явные суммы. Длина описания сама по себе слабая: ρ = 0,27 и прироста не даёт.

КАК ПОНИМАТЬ

Текст — самый сильный источник сигнала: он описывает стек, обязанности, уровень и культуру. Но сырой текст частично содержит саму зарплату, поэтому метрика завышена. После маскировки денежных паттернов качество почти не падает — значит, полезный сигнал о роли остаётся. Это ключевой аргумент, что текст работает не только за счёт утечки.

ЧЕМУ УЧИТ

Для текста обязательна проверка на утечку: суммы, диапазоны, «competitive salary», дубликаты вакансий. Очистка регулярками не идеальна, поэтому вывод «подтверждена с оговоркой» честнее, чем «текст даёт 25,7k». И ещё: случайная CV на текстах одной компании может завышать качество из-за почти одинаковых описаний.

Подтверждена (с оговоркой об утечке)

19 Факт пропуска — сам по себе признак

ВОПРОС

Помогают ли модели индикаторы «здесь нет данных»?

КАК ПРОВЕРЯЛИ

Для каждого из восьми полей сравнили медианы зарплат при наличии и отсутствии значения (Mann–Whitney). Затем добавили все `is_missing_*` к базовой модели и сравнили MAE.

ЧТО ПОЛУЧИЛОСЬ

Описательно пропуски очень информативны: без `seniority` медиана в 1,61 раза выше, без `department` — в 0,71 раза, без `country_code` — в 1,35 раза; все $p < 1e{-}28$. Но прирост MAE отрицательный: −42 доллара. Индикаторы коррелируют друг с другом.

КАК ПОНИМАТЬ

Информация о пропуске уже присутствует в базовых признаках: пропущенная категория закодирована как «Unknown». Добавление отдельных флагов дублирует её и не помогает. Это не значит, что пропуски не важны — значит, что их нужно правильно кодировать, а не добавлять вслепую.

ЧЕМУ УЧИТ

Проверяйте, не дублирует ли новый признак уже существующий. И различайте описательную информативность и incremental value: первое — про структуру данных, второе — про пользу в модели. Отрицательный прирост вполне возможен из-за шума и переобучения.

Частично подтверждена

7.7. Служебные признаки: гипотезы 20–21

20 `salary_min` — самый сильный предиктор `salary_max`

ВОПРОС

Насколько хорошо нижняя граница вилки предсказывает верхнюю?

КАК ПРОВЕРЯЛИ

Две модели на лог-шкале: без `salary_min_usd` и с ним. Плюс permutation importance на hold-out.

ЧТО ПОЛУЧИЛОСЬ

MAE падает с 47,2k до 17,4k; R^2 растёт с 0,47 до 0,92. Важность `salary_min` более чем в 10 раз выше остальных признаков.

КАК ПОНИМАТЬ

Результат почти тривиален: границы одной вилки связаны. Но это не «признак, который улучшает прогноз», а утечка: в момент холодного прогноза нижней границы у нас нет. Практическая польза — восстановление интервалов, когда одна граница известна (например, кандидат назвал ожидания).

ЧЕМУ УЧИТ

Самый сильный предиктор может быть самым бесполезным в продакшене. Всегда спрашивайте: «будет ли это значение доступно в момент предсказания?». Если нет — это не признак, а ответ.

Подтверждена

21 Даты дают слабый, но проверяемый сигнал

ВОПРОС

Есть ли сезонность, эффект дня недели, часа публикации или задержки сбора?

КАК ПРОВЕРЯЛИ

Spearman для lag и «давности»; Kruskal–Wallis по дню недели и часу; модель с добавлением четырёх временных признаков.

ЧТО ПОЛУЧИЛОСЬ

Все вакансии опубликованы в одну неделю: 5–12 октября 2026. День недели формально значим ($p = 0{,}008$), но эффект держится на ~200 выходных вакансиях. Час значим ($p < 1e{-}100$), но 96 % вакансий в 00:00 — это Workday с более низкими зарплатами. Добавление дат ухудшает MAE на 0,3k.

КАК ПОНИМАТЬ

Сезонность проверить невозможно: нет нескольких циклов. «Час публикации» — артефакт источника, а не поведение рынка. День недели — слабый и хрупкий эффект. Для прогноза даты бесполезны; для анализа сезонности нужен длинный период.

ЧЕМУ УЧИТ

Временные признаки легко поймать как артефакт сбора. Если все записи появились в один час, признак «час» будет сильным, но бессмысленным. И для сезонности нужно как минимум несколько лет, а не одна неделя.

Не подтверждена

8. Итоги: что действительно работает

Из 21 гипотезы 14 подтвердились полностью или с оговоркой, 6 — частично, 1 — не подтвердилась. Но главный результат ноутбука не в счёте, а в разделении «статистически значимо» и «полезно для прогноза».

39,9k
MAE базовой модели, $

25,7k
MAE метаданные + очищенный текст, $

0,33
ε^2 исходного периода — максимум

14 / 6 / 1
подтверждена / частично / нет

8.1. Сводная таблица

№	Гипотеза	Проверка	Вывод
1	Логарифм зарплаты как таргет	skew, Jarque–Bera, CV raw/log	Подтверждена (с оговоркой)
2	Один таргет — середина вилки	Pearson/Spearman, CV min/mid/max	Подтверждена
3	Ширина вилки — отдельный сигнал	Spearman, Kruskal–Wallis, CV	Частично
4	Уровень позиции влияет на зарплату	Kruskal–Wallis, Mann–Whitney	Подтверждена
5	Уровень восстанавливается из title	TF-IDF + LogReg, прирост MAE	Частично
6	Семейство профессии значимо	Kruskal–Wallis, CV	Подтверждена
7	department полезен там, где заполнен	Kruskal–Wallis, CV на подвыборке	Подтверждена (на подвыборке)
8	Страна влияет на зарплату	Kruskal–Wallis	Подтверждена
9	remote > hybrid > onsite	тесты + OLS с контролем	Частично
10	Штат/город внутри США значимы	Kruskal–Wallis, CV	Подтверждена
11	Пропуск country_code — сигнал	медианы, χ^2, Mann–Whitney	Частично
12	ats — прокси типа компании	Kruskal–Wallis, CV, permutation	Подтверждена
13	company/company_id полезны	target encoding внутри CV	Подтверждена
14	salary_source — качество данных	χ^2, OLS до/после контроля	Подтверждена
15	employment_type значим	Kruskal–Wallis, CV	Подтверждена (слабый прирост)
16	Исходный период информативен	Kruskal–Wallis, CV	Подтверждена
17	Ошибки периода ухудшают модель	CV: все / без / с флагом	Частично
18	description содержит сигнал	TF-IDF + Ridge, очистка	Подтверждена (с оговоркой)
19	Факт пропуска — признак	Mann–Whitney, CV с флагами	Частично
20	salary_min — предиктор salary_max	CV, permutation importance	Подтверждена
21	Даты дают слабый сигнал	Spearman, Kruskal–Wallis, CV	Не подтверждена

8.2. Рейтинг по пользе для модели

Приросты MAE относительно базовой модели (39,9k). Разные гипотезы добавляют признаки к разным базовым наборам, поэтому сравнивать их между собой можно только как ориентир.

Что добавлено	Прирост MAE	Комментарий
Исходный `salary_period`	+6,6k	Самый сильный категориальный признак, но это формат оплаты и тип роли
Target encoding компании	+2,7k	Требует аккуратной кросс-валидации и сглаживания
`job_family`	+2,2k	Эвристика по title; 34 % в «other»
`seniority_pred` поверх `job_family`	+3,1k	37,7k → 34,6k; есть тонкая утечка при обучении классификатора
`ats`	+1,1k	Прокси типа компании, не причина
`department`	+1,1k	Только на подвыборке с заполненным полем
Штат США	+0,9k	Покрытие 82 % американских вакансий
`employment_type`	+0,3k	Значим, но во многом дублирует период
Даты	−0,3k	Ухудшают модель
Флаги пропусков	−42 $	Дублируют категорию «Unknown»
Описание (очищенное) вместо метаданных	−13,5k (MAE)	Другой класс модели, поэтому сравнимо только качественно

8.3. Рекомендуемый набор признаков

Для «холодного» прогноза, когда зарплата вакансии неизвестна:

- `raw_period`, `ats`, `country_code`, `state_model`, `employment_type`, `workplace_type`;
- `job_family`, `seniority_pred`, `dept_group`;
- target encoding `company` / `company_id` — только внутри train-фолдов;
- очищенный от денежных упоминаний текст описания (TF-IDF или эмбеддинги);
- флаг `period_suspect` — только для диагностики.

Не включать в холодный прогноз `salary_min` и `salary_max`: они дают «идеальные» метрики, но это утечка. Их место — восстановление интервалов, когда одна из границ уже известна.

8.4. Ограничения

- Данные наблюдательные и только по вакансиям с указанной зарплатой — selection bias.
- Одна неделя наблюдения: сезонность и тренды не проверить.
- Курсы валют зафиксированы на одну дату; пересчёт периода использует стандартные 2 080 часов и 260 дней.
- Множественные проверки: p-value — ориентир, а не окончательное доказательство.
- Семейства профессий и штаты извлечены эвристиками; seniority заполнен у 7 %.
- Случайная кросс-валидация, а не временная; возможны дубликаты вакансий и компаний между фолдами.

8.5. Что делать дальше

1. Собрать более длинную историю и проверить сезонность/тренды на временном hold-out.
2. Заменить эвристики `job_family` и `seniority` на обучаемые модели по title/description.
3. Добавить эмбеддинги описания и попробовать градиентный бустинг поверх них.

4. Перейти от точечного прогноза к квантильной регрессии — для вилки и интервалов.
5. Отдельно моделировать почасовые и part-time вакансии: у них другой механизм формирования зарплаты.

9. Как применять это на практике

Ноутбук — это шаблон исследования. Его можно переиспользовать на других данных: важно не копировать код, а повторять последовательность решений.

9.1. Алгоритм проверки своей гипотезы

1. **Сформулируйте утверждение.** Не «интересно, влияет ли страна», а «медианная зарплата в США выше, чем в Германии».
2. **Определите единицу наблюдения и таргет.** Одна строка — одна вакансия; таргет — середина вилки в долларах в год.
3. **Очистите данные до анализа.** Приведите единицы, определите пропуски, зафиксируйте правила. Не подгоняйте правила под желаемый результат.
4. **Посмотрите на данные глазами.** Медианы, размеры групп, боксплоты. Это подскажет, какой тест уместен и нет ли выбросов.
5. **Проверьте предположения теста.** Нормальность, равенство дисперсий, независимость. Если они нарушены — берите ранговый тест.
6. **Посчитайте p-value и размер эффекта.** Одно без другого не читается.
7. **Проверьте устойчивость.** Разбейте данные иначе, уберите выбросы, посмотрите подгруппы. Если вывод меняется — он хрупкий.
8. **Проверьте пользу для модели.** Добавьте признак и сравните MAE на одних и тех же фолдах.
9. **Сформулируйте вывод с ограничениями.** «Связано», а не «влияет»; «среди вакансий с указанной зарплатой», а не «на рынке».
10. **Запишите результат в журнал.** Номер, метод, число, вердикт. Как `add_summary` в ноутбуке.

9.2. Чек-лист перед публикацией вывода

Проверка	Почему это важно
Гипотеза сформулирована до анализа?	Иначе это post-hoc объяснение, а не проверка
Есть H_0 и H_1 в явном виде?	Без них p-value не имеет смысла
Указан размер каждой группы?	Маленькие группы дают нестабильные оценки
Указан размер эффекта?	Значимость не говорит о величине
Учтены множественные сравнения?	Иначе 5 % «находок» — случайность
Проверены конфаундеры?	Разница может быть составом выборки
Нет утечки из таргета?	Иначе метрика красивая, а модель бесполезна
Метрика сравнивается на одних фолдах?	Иначе разница — шум разбиения
Вывод сформулирован без причинности?	Наблюдательные данные не доказывают причину
Ограничения названы явно?	Честность важнее уверенного тона

9.3. Десять типичных ошибок

1. «p < 0,05 — значит, гипотеза доказана»

p-value — вероятность данных при H_0, а не вероятность H_0. И оно ничего не говорит о величине эффекта. Смотрите на медианы, проценты, ε^2 и прирост MAE.

2. Сравнивать средние на скошенных данных

Один выброс в 600k сдвигает среднее и создаёт ложное впечатление. Для зарплат используйте медианы и ранговые тесты.

3. Игнорировать размер группы

Разница между группами 5 и 10 000 наблюдений может быть «значимой» только за счёт большой группы. И наоборот: незначимость на 23 наблюдениях — не доказательство равенства.

4. Делать десятки проверок без поправки

21 гипотеза и десятки парных тестов — почти гарантия ложных находок. Используйте Бонферрони или FDR и называйте анализ исследовательским.

5. Путать корреляцию с причинностью

«Remote дороже» может означать «в remote больше senior-вакансий». Контроль на наблюдаемые признаки помогает, но не доказывает причину.

6. Считать feature importance «истинной важностью»

Permutation importance зависит от модели и коррелированных признаков. Она отвечает на вопрос «что важно этой модели», а не «что важно миру».

7. Допускать утечку через target encoding

Кодирование по всей таблице, а потом разбиение — классическая ошибка. Энкодер обучается только на train-фолде, с внутренней CV и сглаживанием.

8. Использовать `salary_min` для прогноза `salary_max`

Это не прогноз, а восстановление одной части вилки по другой. В холодном сценарии такой признак недоступен.

9. Верить текстовой модели без проверки на утечку

87 % описаний содержат суммы. Маскируйте деньги и проверяйте, остаётся ли сигнал; следите за дубликатами вакансий.

10. Оценивать только средний MAE

Средняя ошибка скрывает хвосты. Строки с ошибкой периода — 0,5 % данных, но ошибка на них около 500k. Смотрите распределение ошибок и подгруппы.

9.4. Вопросы и ответы

Почему не использовать обычный t-тест?

Из-за скошенности, выбросов и разной дисперсии. Ранговые тесты устойчивее и не требуют нормальности. Если данных много, t-тест тоже даст результат, но медианы и Kruskal–Wallis лучше описывают зарплаты.

Почему таргет — середина вилки, а не конкретная зарплата?

Конкретной зарплаты в данных нет: есть только вилка. Середина — компромисс, который не занижен и не завышен. Если бизнес-вопрос требует min или max, нужно моделировать именно их.

Почему логарифм, если MAE в долларах всё равно считается?

Модель обучается на логе, потому что относительные ошибки важнее абсолютных и распределение симметричнее. Метрику потом возвращают в доллары через `expm1`, чтобы её можно было объяснить бизнесу.

Что такое ε^2 и чем он лучше p-value?

ε^2 — доля вариации, объяснённая группами, нормированная на размер выборки. Он не растёт автоматически с n, поэтому позволяет сравнивать эффекты между признаками: 0,01 — мало, 0,06 — средне, 0,14 — много.

Почему прирост MAE может быть отрицательным?

Признак добавляет шум, дублирует существующий или провоцирует переобучение. Это нормальный результат: не каждый значимый признак полезен.

Можно ли использовать `company` в модели, если компаний 4 000?

Да, через target encoding с обучением внутри train, сглаживанием и запасным значением для новых компаний. One-hot на 4 000 категорий создаст разреженную и нестабильную матрицу.

Почему описание даёт такой большой выигрыш?

Оно содержит стек, обязанности, уровень и контекст роли. Но часть выигрыша — утечка из явных сумм. После маскировки сигнал остаётся, хотя метрика становится чуть хуже.

Можно ли доверять выводу про remote?

Как описательной ассоциации — да, с оговоркой. Как причинному утверждению — нет: остаются ненаблюдаемые различия компаний и вакансий. И p = 0,015 после множества проверок хрупок.

10. Словарь терминов

Термин	Простое объяснение
Генеральная совокупность	Все объекты, о которых мы хотим сделать вывод. Здесь — все вакансии с раскрытой зарплатой.
Выборка	То, что у нас есть: 9 173 строки. По ней мы судим о совокупности.
H_0 / H_1	Нулевая гипотеза («различий нет») и альтернативная («различия есть»).

Термин	Простое объяснение
p-value	Вероятность увидеть такие данные (или более экстремальные), если H_0 верна. Не вероятность H_0.
α (уровень значимости)	Порог, ниже которого отвергаем H_0. Обычно 0,05.
Ошибка I рода	Ложноположительный результат: различий нет, а мы их «нашли».
Ошибка II рода	Пропустили реальный эффект: различия есть, а тест их не увидел.
Мощность	Вероятность обнаружить эффект, если он есть. Растёт с размером выборки и величиной эффекта.
Непараметрический тест	Тест, не требующий нормальности; часто работает с рангами.
Kruskal–Wallis	Непараметрический аналог ANOVA для 3+ групп: «есть ли сдвиг хотя бы в одной».
Mann–Whitney U	Непараметрическое сравнение двух групп по рангам.
χ^2 (хи-квадрат)	Тест связи двух категориальных переменных.
Размер эффекта	Насколько различие велико в содержательных единицах: ε^2, r, проценты, доллары.
ε^2 (эпсилон-квадрат)	Доля объяснённой вариации для Kruskal–Wallis; 0,01 / 0,06 / 0,14 — мало / средне / много.
Множественные сравнения	Много проверок на одних данных → растёт риск ложных находок. Лечится Бонферрони или FDR.
Кросс-валидация	Многократное деление данных на train/test, чтобы оценить модель устойчиво.
Out-of-fold предсказание	Предсказание для строки моделью, которая её не видела.
Утечка (leakage)	В признаки попала информация о таргете или из будущего. Метрики становятся слишком хорошими.
MAE	Средняя абсолютная ошибка: «в среднем ошибаемся на N долларов».
RMSLE	Ошибка в лог-шкале: чувствительна к относительным, а не абсолютным отклонениям.
R^2	Доля дисперсии таргета, объяснённая моделью. Сравнивать только в одной шкале.
skew (асимметрия)	Мера скошенности распределения. 0 — симметрично, > 0 — хвост справа.
Jarque–Bera	Тест на нормальность через асимметрию и эксцесс.
QQ-plot	График: квантили данных против квантилей нормального распределения. Прямая линия — похоже на нормальное.
IQR / правило Тьюки	Межквартильный размах; границы Q1 − 1,5·IQR и Q3 + 1,5·IQR для поиска выбросов.
Конфаундер	Третий фактор, который влияет и на признак, и на таргет и создаёт ложную связь.
Target encoding	Замена категории средним таргетом по ней; требует обучения внутри train и сглаживания.
TF-IDF	Превращение текста в числа: важность слова = частота в документе × редкость во всём корпусе.
Ridge	Линейная регрессия с L2-штрафом: уменьшает переобучение, особенно на тексте.
Permutation importance	Важность признака: перемешиваем его значения и смотрим, насколько упало качество.
Градиентный бустинг	Ансамбль деревьев, где каждое следующее исправляет ошибки предыдущих.
Смещение выборки	Данные не отражают совокупность: например, только вакансии с указанной зарплатой.
MNAR / MAR / MCAR	Типы пропусков: связан с самим значением / с другими признаками / ни с чем.

Приложение. Формулы и шпаргалка по коду

A.1. Формулы

Величина	Формула / правило
Середина вилки	`(salary_min_usd + salary_max_usd) / 2`
Приведение к году	`сумма × коэффициент_периода / курс_валюты`
Логарифм таргета	`log1p(x) = ln(1 + x)`; обратно `expm1(z) = e^z − 1`
Границы Тьюки	`Q1 − 1,5·IQR` и `Q3 + 1,5·IQR`, где `IQR = Q3 − Q1`
ε^2	`(H − k + 1) / (n − k)`
Перевод β в проценты	`(exp(β) − 1) × 100`
MAE	$(1/n) \cdot \Sigma \lvert y_i - \hat{y}_i \rvert$
RMSE	$\sqrt{(1/n) \cdot \Sigma (y_i - \hat{y}_i)^2}$
RMSLE	$\sqrt{(1/n) \cdot \Sigma (\log1p(y_i) - \log1p(\hat{y}_i))^2}$
R^2	`1 − SS_res / SS_tot`
Бонферрони	`p_adj = min(1, p × m)`, где m — число проверок
Target encoding со сглаживанием	`(n·mean_category + m·global_mean) / (n + m)`, m — сила сглаживания

A.2. Мини-шаблон проверки гипотезы

```
from scipy import stats
import numpy as np

# 1. Подготовка
sub = df[df["workplace_type"].isin(["remote", "onsite"])].dropna(subset=["salary_mid"])

# 2. Описательная статистика
print(sub.groupby("workplace_type")["salary_mid"].agg(["median", "size"]))

# 3. Тест на различия (2 группы)
x = sub.loc[sub.workplace_type == "remote", "salary_mid"]
y = sub.loc[sub.workplace_type == "onsite", "salary_mid"]
u, p = stats.mannwhitneyu(x, y)
print(f"U = {u:.0f}, p = {p:.4f}")

# 4. Размер эффекта: разница медиан и процент
med_x, med_y = x.median(), y.median()
print(f"Медианы: {med_x:,.0f} vs {med_y:,.0f}; разница {(med_x/med_y - 1)*100:.1f}%")

# 5. Проверка на модели (общие фолды!)
pred_with = cv_predict(df[BASE], df.log_salary,
                       extra={"workplace_type": df["workplace_type"]})
mae_with = mean_absolute_error(df.salary_mid, np.expm1(pred_with))
print(f"MAE без/с признаком: {BASE_METRICS['MAE, $']:,} / {mae_with:,.0f}")
```

A.3. Шаблон Kruskal–Wallis

```
res = kruskal_table(df, "salary_mid", "job_family", min_n=50)
print(f"H = {res['H']:.1f}, p = {pfmt(res['p'])}, eps2 = {res['eps2']:.2f}")
display(res["table"])

# Пост-хок: только для заранее выбранных пар, с поправкой
pairs = [("engineering", "sales"), ("engineering", "admin")]
display(pairwise_mw(df, "salary_mid", "job_family", pairs).round(3))
```

A.4. Шаблон target encoding

```
# Внутри каждого фолда: fit только на train, transform на test
pred = cv_predict_target_encoding(df[BASE], df.log_salary, "company")

# Никогда так не делать:
# df["company_mean"] = df.groupby("company")["log_salary"].transform("mean")
# Это утечка: среднее уже содержит таргет тестовой строки.
```

A.5. Карта файлов проекта

Путь	Назначение
`notebooks/hypothesis_testing.ipynb`	Этот ноутбук: подготовка, 21 гипотеза, сводка
`notebooks/eda_salary.ipynb`	Разведочный анализ, из которого выросли гипотезы
`notebooks/salary_prediction.ipynb`	Место для модели прогнозирования (пока пустой)
`src/utils.py`	Загрузка данных по пути относительно корня проекта
`data/raw/job_postings_with_salaries.csv`	Исходные данные
`docs/hypothesis_testing_guide.pdf`	Эта методичка

A.6. Что запомнить из всего документа

ПЯТЬ МЫСЛЕЙ

1. **Сначала данные, потом тесты.** Единицы, пропуски и выбросы решают больше, чем выбор теста.
2. **p-value — не размер эффекта.** Всегда показывайте величину: медианы, проценты, ε^2, доллары.
3. **Значимость ≠ польза для модели.** Проверяйте incremental value на общих фолдах.
4. **Самый сильный признак может быть утечкой.** Спрашивайте, доступен ли он в момент прогноза.
5. **Наблюдательные данные не доказывают причинность.** Пишите «связано», а не «влияет».

Методичка подготовлена по ноутбуку `notebooks/hypothesis_testing.ipynb` проекта «Job Postings with Salaries». Числа и выводы соответствуют версии ноутбука на дату подготовки; при изменении данных или библиотек результаты могут незначительно отличаться.